

文本复制检测报告单(去除本人已发表文献)

№:ADBD2019R_2016032813113620190504214857435080939814

检测时间:2019-05-04 21:48:57

检测文献: 50264765936905568_姜希成_本科论文

作者: 姜希成

检测范围: 中国学术期刊网络出版总库

中国博士学位论文全文数据库/中国优秀硕士学位论文全文数据库

中国重要会议论文全文数据库

中国重要报纸全文数据库

中国专利全文数据库

图书资源

优先出版文献库

大学生论文联合比对库

互联网资源(包含贴吧等论坛资源)

英文数据库(涵盖期刊、博硕、会议的英文数据以及德国Springer、英国Taylor&Francis 期刊数据库等)

港澳台学术文献库

互联网文档资源

CNKI大成编客-原创作品库

个人比对库

时间范围: 1900-01-01至2019-05-04

检测结果

去除本人已发表文献复制比: 11%

重复字数: [2668]

总字数: [24166]

疑似段落最大重合字数: [1591]

总段落数: [2]

前部重合字数: [956]

疑似段落最小重合字数: [1077]

疑似段落数: [2]

后部重合字数: [1712]

指标: ☐ 疑似剽窃观点 ☒ 疑似剽窃文字表述 ☐ 疑似自我剽窃 ☐ 疑似整体剽窃 ☐ 过度引用

表格: 0 公式: 16 疑似文字的图片: 0 脚注与尾注: 0

10.8% (1077) 50264765936905568_姜希成_本科论文_第1部分 (总9942字)

11.2% (1591) 50264765936905568_姜希成_本科论文_第2部分 (总14224字)



(注释: ■ 无问题部分 ■ 文字复制部分)

1. 50264765936905568_姜希成_本科论文_第1部分

总字数: 9942

相似文献列表

去除本人已发表文献复制比: 10.8%(1077) 文字复制比: 10.8%(1077) 疑似剽窃观点: (0)

1	20142203712-朱宝亮-基于SSH的物流配送系统的设计与实现 朱宝亮 - 《大学生论文联合比对库》 - 2018-05-10	6.3% (626) 是否引证: 否
2	20112212554-肖寒君-基于Kinect的人形机器人动作模仿设计与实现 肖寒君 - 《大学生论文联合比对库》 - 2015-05-08	6.3% (622) 是否引证: 否
3	20113615898-王超-电气2班-基于协同遗传算法的轮毂永磁同步电动机的优化设计 王超 - 《大学生论文联合比对库》 - 2015-05-21	6.2% (618) 是否引证: 否
4	20103415238-董广绰-望武路朱河桥设计 董广绰 - 《大学生论文联合比对库》 - 2014-05-27	6.1% (607) 是否引证: 否
5	20091410855-杨昌瑞-中法足球现状对比 杨昌瑞 - 《大学生论文联合比对库》 - 2013-05-27	6.1% (605) 是否引证: 否
6	20102212360-陈晨-《服装公司管理系统》设计与实现 陈晨 - 《大学生论文联合比对库》 - 2014-05-12	5.9% (591) 是否引证: 否
7	20092212522-丁辉-基于J2EE的航空公司售票系统的设计 丁辉 - 《大学生论文联合比对库》 - 2013-05-24	5.8% (575) 是否引证: 否
8	20092413040-胥大莉-荧光淬灭法研究石松定碱与牛血清白蛋白的反应机理 胥大莉 - 《大学生论文联合比对库》 - 2013-05-28	5.7% (569) 是否引证: 否

9	20092212522-丁辉-J2EE开发的机票系统的设计 丁辉 - 《大学生论文联合比对库》 - 2013-05-28	5.7% (568) 是否引证：否
10	20141302014-郑洁-论华洋义赈会的灾荒救助 郑洁 - 《大学生论文联合比对库》 - 2018-05-15	5.6% (557) 是否引证：否
11	20093314809-李鹏-第30届伦敦奥运会中国女排二传分配球效果分析 李鹏 - 《大学生论文联合比对库》 - 2013-05-27	5.5% (550) 是否引证：否
12	20092513361-赵会芳-年产2000吨结冷胶工厂设计 赵会芳 - 《大学生论文联合比对库》 - 2013-05-28	5.1% (509) 是否引证：否
13	20093314810-李晓庆-左右手打好乒乓球的可能性分析 李晓庆 - 《大学生论文联合比对库》 - 2013-05-27	5.0% (501) 是否引证：否
14	20092212335-由斌斌-车牌识别系统设计与实现 由斌斌 - 《大学生论文联合比对库》 - 2013-05-24	5.0% (499) 是否引证：否
15	20092513210-侯兰梅-不同种子资源毛冰草的耐盐性差异分析 侯兰梅 - 《大学生论文联合比对库》 - 2013-05-28	4.8% (476) 是否引证：否
16	20091110034-张恒元-主流时尚的传媒文化引发的山寨效应 张恒元 - 《大学生论文联合比对库》 - 2013-05-22	4.7% (469) 是否引证：否
17	20092212397-范又瑞-bbs网络论坛 范又瑞 - 《大学生论文联合比对库》 - 2013-05-24	4.7% (463) 是否引证：否
18	20092212437-杜健-打印报表 杜健 - 《大学生论文联合比对库》 - 2013-05-24	4.6% (457) 是否引证：否
19	20092212461-王业明-医药销售系统的设计与发展前景 王业明 - 《大学生论文联合比对库》 - 2013-05-24	4.6% (457) 是否引证：否
20	20092212558-张汝露-教学资源管理系统 张汝露 - 《大学生论文联合比对库》 - 2013-05-24	4.6% (455) 是否引证：否
21	20092925996-孙学亭-热泵实验室的温湿度控制系统 孙学亭 - 《大学生论文联合比对库》 - 2013-05-24	4.6% (453) 是否引证：否
22	20092613704-冯怀玲-山东省区域产业结构比较研究 冯怀玲 - 《大学生论文联合比对库》 - 2013-05-24	4.5% (451) 是否引证：否
23	20092212380-许春海-基于android平台的手机安全卫士设计 许春海 - 《大学生论文联合比对库》 - 2013-05-24	4.5% (448) 是否引证：否
24	20092212257-张光岳-无线校园网的设计与优化 张光岳 - 《大学生论文联合比对库》 - 2013-05-24	4.5% (448) 是否引证：否
25	20091110069-王绍朋-从假新闻来看新闻真实性的维护 王绍朋 - 《大学生论文联合比对库》 - 2013-05-22	4.5% (444) 是否引证：否
26	张颂怡G11110223+论文 - 《大学生论文联合比对库》 - 2014-02-24	0.9% (92) 是否引证：否
27	流形学习及其算法分析 冯灵清;刘艳红;刘宇晶; - 《计算机时代》 - 2017-04-15	0.6% (60) 是否引证：否
28	数据结构中的动感形态研究与应用实践 刘华敏; - 《山东农业工程学院学报》 - 2017-08-15	0.6% (58) 是否引证：否
29	5170698基于OpenCV和Python的机器视觉脸部检测与识别 - 《大学生论文联合比对库》 - 2018-05-03	0.5% (54) 是否引证：否
30	一种改进的深度学习人脸识别算法研究 伊力哈木·亚尔买买提; - 《计算机仿真》 - 2017-11-15	0.4% (41) 是否引证：否
31	基于图像识别技术的支付系统设计研究 项佳玮(导师：王昀;雷达;刘征) - 《中国美术学院博士论文》 - 2018-04-01	0.3% (31) 是否引证：否
32	人脸识别技术未来将走向算法免费 王海增; - 《中国安防》 - 2017-02-01	0.3% (29) 是否引证：否

原文内容

毕业设计开题报告

姓名学院年级 2015 学号

题目基于流形学习子空间的人脸识别算法

课题来源教师推荐课题类别应用研究

选题意义（包括科学意义和应用前景，研究概况，水平和发展趋势，列出主要参考文献目录）：

近年来，人脸识别市场得到了突飞猛进的发展，早在2017年，其市场规模就已经超过40.5亿美元，预计2022年会超过

77.6亿美元，因此人脸识别技术的市场前期非常好，这预示着人脸识别的爆点已经到来，而且经过长时间的积淀，人脸识别技术已经十分成熟，而流形学习是进行人脸识别的常用方法，流形学习自上世纪60年代首次被提出到现在已经发展了近60年，相继出现许多经典算法和经典理论，所以非常具有研究价值，本文将人脸识别为应用背景，对几种流形学习方法进行研究。

主要参考文献：

[3] 王庆军，张汝波，刘冠群. 一种应用于人脸识别的核正交等度映射算法[N]. 光电子激光，2010(11).

[32] 左加阔. 基于流形学习算法的新生儿疼痛表情识别[D]. 南京邮电大学: 信号与信息处理，2011.

[33] 陶晓燕，姬红兵，景志宏. 一种用于人脸识别的正交邻域保护嵌入算法[N]. 西安电子科技大学学报（自然科学版），2008(6).

[41] 陈江峰. 线性图嵌入算法及其应用[D]. 北京交通大学: 信号与信息处理，2012.

[42] 华校专，王正林. Python大战机器学习：数据科学家的第一个小目标[M]. 北京: 电子工业出版社，2017.

研究主要内容和预期结果（说明具体研究内容和拟解决的关键问题，预期结果和形式，如在理论上解决哪些问题及其价值，或应用的可能性及效果）：

主要研究内容：本文将主要介绍邻域保护嵌入算法（NPE）和等距映射算法（IsoProjection），并在其基础上进一步优化这两种算法，即改进为正交邻域保护嵌入算法（ONPE）和正交等距映射算法（OlsoProjection）。

预期结果：在NPE算法和IsoProjection算法的基础上，通过正交化的方法改进出ONPE算法和OlsoProjection算法，进一步提升这两种算法的识别率，并在ORL人脸库和Yale人脸库上验证这两种改进算法的有效性。

拟采取的研究方法和技术路线（包括理论分析、计算，实验方法和步骤及其可行性论证，可能遇到的问题和解决方法，以及研究的进度与计划）：

研究方法：实验法、经验总结法、文献研究法、功能分析法

技术路线：通过查阅整理相关学习资料学习流形学习的相关算法如MDS算法，ISOMAP算法，LLE算法，NPE算法和IsoProjection算法等，并使用MATLAB软件运行这些算法并分析算法原理，有了一定的基础后再在NPE算法和IsoProjection算法的基础上引入正交化的功能，并在MATLAB上实现这两种算法，最后在ORL人脸库和Yale人脸库上验证这两种算法的有效性。

研究的进度与计划：2019年3月1日，选题。

2019年3月1日---2019年3月6日，查阅并整理相关资料。

2019年3月6日---2019年3月10日，完成开题报告。

2019年3月10日---2019年4月20日，完成程序创建与前期功能实现。

2019年4月20日---2019年5月1日，完善程序功能，完成论文初稿。

指导教师意见（对论文选题的意义、应用性、可行性、进度与计划等内容进行评价，填写审核结果：同意开题、修改后再开题、不同意开题）：

该生对本课题相关的知识与理论研究比较透彻，参考了许多的文献资料，具有一定的研究价值。

本课题结构合理，内容完整，主要观点突出，并且时效性强，是学生学习方向的延续，对于提高学生的能力有利。

同意该课题开题。

签名：

年月日

学院毕业设计领导小组意见：

（签章）

年月日

毕业设计结题报告

姓名姜希成学院年级 2015 学号 20152203031

题目基于流形学习子空间的人脸识别算法

课题来源教师推荐课题类别应用研究

本课题完成情况介绍（包括研究过程、实验过程、结果分析、存在的问题及应用情况等。）

研究过程：查阅大量流形学习和人脸识别的相关文献，并学习流形学习相关算法的实现原理如MDS算法、ISOMAP算法、NPE算法和IsoProjection算法，在查阅许多正交化改进算法方法有关的文献后自己动手改进出正交算法，即ONPE算法和OlsoProjection算法。

实验过程：在ORL人脸库和Yale人脸库上运行ONPE算法和OlsoProjection算法，并对比之前学过的其他算法，分析各个算法之间的特点。

结果分析：ONPE算法和OlsoProjection算法确实可以提高原算法的识别率。

存在的问题：（1）改进的算法识别率没有预期的高，还需进一步改进算法。（2）还有许多算法的原理没有搞明白，需要进一步学习。（3）在算法改进过程中遇到许多问题还未解决，因为时间有限，虽然最终程序能跑出来，但是还是不够完美，还有改进的可能。

指导教师评语：

该生对本课题相关的知识与理论研究比较透彻，本设计基本实现了需求所描述的功能。

设计选题新颖，功能全面，应用到的技术较多，时效性强。

同意结题。

签名：

年月日

学院毕业设计领导小组意见：

(公章)

年月日

指导教师

评定成绩

毕业设计成绩评定表

学院：学号：20152203031

姓名姜希成总成绩

题目基于流形学习子空间的人脸识别算法

评

阅

人

评

语

评定成绩：评阅人（签名）：年月日

答

辩

小

组

评

语

答辩成绩：答辩组成员（签名）：年月日

注：总成绩=指导教师评定成绩（40%）+评阅人评定成绩（20%）+答辩成绩（40%），将总成绩由百分制转换为五级制，填入本表相应位置。

目录

1引言	9
1.1人脸识别技术简介	10
1.1.1人脸识别技术的发展情况	10
1.1.2人脸识别技术的优势	10
1.1.3人脸识别技术的市场前景	10
1.1.4人脸识别系统的研究内容	11
1.2流形学习	11
1.2.1流形学习的研究背景	11
1.2.2流形学习的发展情况	12
1.2.3流形的定义	12
1.3小结	13
2流形学习相关算法	13
2.1规范正交基	13
2.1.1施密特(Schmidt)正交化	13
2.1.2单位化	14
2.2迪杰斯特拉(Dijkstra)算法	14
2.2.1迪杰斯特拉(Dijkstra)算法原理	14
2.2.2迪杰斯特拉(Dijkstra)算法步骤	14
2.3 多维缩放(MDS)算法	15
2.3.1 MDS算法推导	15
2.3.2 MDS算法流程	16
2.4 等度量映射(ISOMAP)算法	17
2.4.1 ISOMAP算法步骤	17
2.4.2 ISOMAP算法流程	18
2.4.3 ISOMAP算法的优点	18
2.4.4 ISOMAP算法的缺点	18
2.5线性图嵌入算法(LGE)	18
2.5.1 LGE算法推导	19
2.6局部线性嵌入算法 (LLE)	19
2.6.1 LLE算法原理	20
2.6.2 LLE算法推导	20
2.6.3 LLE算法流程	20
2.7等距映射算法 (IsoProjection)	21
2.7.1 IsoProjection算法推导	21
2.7.2 IsoProjection算法流程	21
2.8领域保护嵌入算法 (NPE)	22

2.8.1 NPE算法推导	22
2.8.2 NPE算法流程	22
3正交化算法	23
3.1 OlsoProjection	23
3.1.1 OlsoProjection算法推导	23
3.1.2 OlsoProjection算法流程	25
3.2 ONPE	25
3.2.1 ONPE算法推导	25
3.2.2 ONPE算法流程	27
4算法实现	27
4.1常用的人脸数据库介绍	27
4.1.1 ORL人脸库	27
4.1.2 Yale人脸库	28
4.2实验结果	29
4.2.1 NPE	29
4.2.2 ONPE	29
4.2.3 IsoProjection	29
4.2.4 OlsoProjection	29
4.3各个算法的性能对比	30
5结束语	30
6附录	30
6.1 主要算法的核心代码	30
6.1.1 IsoProjection算法	30
6.1.2 NPE算法	32
6.1.3 LGE算法	33
参考文献	36
致谢	39

基于流形学习子空间的人脸识别算法

姜希成

(2015级2班, 20152203031)

摘要：近年来，人脸识别技术得到突飞猛进的发展，与此同时，流形学习方法也取得巨大进展，所以本文以人脸识别为应用背景，对几种常见的流形学习算法进行研究。主要研究了等距映射算法 (IsoProjection)、邻域保护嵌入算法 (NPE) 以及正交的等距映射算法 (OlsoProjection) 和正交的邻域保护嵌入算法 (ONPE)。在本文最后将对这些算法进行对比，研究每种算法的优缺点，并在ORL人脸库上进行试验，验证这些算法的有效性。

关键字：人脸识别，流形学习，数据降维，线性图嵌入，邻域保护嵌入，正交邻域保护嵌入，等距映射，正交等距映射，多维缩放算法，等度量映射，局部线性嵌入，正交化。

Face recognition algorithm based on manifold learning subspace

Jiang XiCheng

Abstract: In recent years, face recognition technology has developed by leaps and bounds. At the same time, the manifold learning method has made great progress. Therefore, this paper uses face recognition as the application background to study several common manifold learning algorithms. The isometric mapping algorithm (IsoProjection), the neighborhood protection embedding algorithm (NPE) and the orthogonal isometric mapping algorithm (OlsoProjection) and the orthogonal neighborhood protection embedding algorithm (ONPE) are mainly studied. At the end of the paper, we compare these algorithms, study the advantages and disadvantages of each algorithm, and test on the ORL face database to verify the effectiveness of these algorithms.

Key words: Face recognition, Manifold Learning, Data reduction dimension, LGE, NPE, ONPE, IsoProjection, OlsoProjection, MDS, ISOMAP, LLE, Orthogonal .

1引言

人脸识别技术和扩展已应用于生活的各个方面，人脸识别技术具有广泛的应用前景，可以用于考勤、门禁、关口同行、社区安防、民航、保险、军事安全、银行金融系统、追击嫌疑犯和反恐等等。近年来，人脸识别技术及相关算法的飞速发展也为该技术提供了强有力的支持。

人脸识别技术在生物特征识别技术中占据非常重要的位置，本文将介绍如何使用流形学习子空间方法来实现人脸识别技术。

1.1人脸识别技术简介

党的十九大报告提出要推进互联网、大数据、人工智能和实体经济的深度融合，人脸识别技术作为人工智能与实体经济相结合的重要技术支撑，近几年来得到飞速发展。

1.1.1人脸识别技术的发展情况

人脸识别在生物特征识别技术中占据非常重要的位置，人脸识别技术不仅具有非侵犯性，而且符合人们自身识别习惯，是一种非常“人性化”的技术。

人脸识别技术从上世纪60年代开始，到现在已经发展了将近60年，在这60年中人脸识别技术得到突飞猛进的发展，相继

出现了许多经典算法、经典思想和经典的人脸数据库。

当前，人脸识别技术的最高识别率已经超过了99.5%，然而，在同等条件下的最高人眼识别率仅为97.52%。所以，人脸识别的准确率已经做到了比肉眼更精准，我相信在未来人脸识别技术一定能我们创造更加便利的生活条件。

1.1.2 人脸识别技术的优势

人脸识别是生物识别的一种，生物识别因为具有易检测、唯一性和终身不变的特点，所以十分适合互联网时代用户对安全的需求，如今生物识别技术的识别速度更快，准确率更高，因此也更具有研究的价值。

目前主流的生物识别技术有人脸识别、指纹识别、虹膜识别、语音识别、静脉识别等。相对于其他的生物识别技术，人脸识别技术的成本更低、稳定性更好、准确率更高，因此也更具有发展优势，所以在多数应用场景中都会首选人脸识别技术。

1.1.3 人脸识别技术的市场前景

市场前景是判断一项技术是否有研究价值的重要指标。

人脸识别市场前景非常好，发展势头也非常迅速，2017年全球人脸识别的市场规模超过40.5亿美元，预计2022年达到77.6亿美元，复合年增长率高达13.9%

根据前瞻产业研究院的报告，目前，人脸识别技术主要应用在考勤和门禁等领域，其市场份额比率约占42%；安防是人脸识别技术最早的应用领域之一，它市场份额比率约占30%；作为未来人脸识别的重要应用领域之一，金融领域，其市场份额比率约占20%。从市场需求的产品结构来看，嵌入式设备约占人脸识别市场的53%，剩下的是软件开发包(SDK)支持的联机应用。

同时大规模普及的软硬件基础条件已具备，产品系列达20多种类型，金融、安防、互联网等主要下游领域需求强劲，这一切都标志着人脸识别技术的爆点已经到来。

1.1.4 人脸识别系统的研究内容

图1-1显示了人脸识别的一般步骤：

特征提取与选择训练人脸图像库图像人脸的检测与定位图像的预处理

特征提取与选择获取人脸图像人脸的检测与定位图像的预处理识别

图 1-1

可见人脸识别系统一般包括人脸检测与定位、图像预处理、人脸图像的特征提取与选择等。横线上方的为人脸识别系统的训练部分，横线下方的人脸识别系统的识别部分。

人脸识别系统在进行特征提取之前需要进行人脸检测与定位和图像预处理，这些操作主要包括几何归一化和灰度归一化。几何归一化是根据人脸检测定位的结果将图像中的人脸变换到同一位置和大小，灰度归一化是将图像进行光照补偿等处理来克服图像中的光照变化对人脸识别的影响。人脸识别过程是将待识别图像的特征和库中的特征进行比对匹配来确定图像中人脸的身份。

1.2 流形学习

流形学习的主要思想是将高维的数据映射到低维，使该低维的数据能够反映原高维数据的某些本质结构特征。

流形学习的前提是有一种假设，即某些高维数据，实际是一种低维的流形结构嵌入在高维空间中。流形学习的目的是将其映射回低维空间中，揭示其本质。

1.2.1 流形学习的研究背景

随着互联网时代的发展，在各个研究领域，每时每刻都在快速生成大量的数据，而在这些数据背后的规律却难以发现，人们虽然获取了海量的信息却发现自己正处于“数据丰富，知识匮乏”的尴尬境地，因此如何从海量信息中提取自己所需的知识是当今各个领域共同面临的巨大挑战。

在许多实际应用中，尤其是在人脸识别中，往往要对成千上万张图片进行处理，而每张图片又有极高的维度，这种高维的特质往往隐藏了数据间关系的本质，对于传统的数据分析方法往往会造成“维数灾难”，这种情况就需要通过降维来把高维空间的数据间的关系映射到低纬度空间，这样就可以更加方便快速的处理数据。因此降维就成了这一任务吸引了许多科研人员的注意，也成为了如人脸识别、机器学习和数据挖掘等领域的热门研究问题。而流形学习就是解决这类问题的方案之一。

自从流形学习方法被提出到现在，研究它的工作就一直在进行着，特别是近年来随着数据挖掘和人脸识别等技术的高速发展，“维数灾难”的问题就成了相关研究领域的重大障碍。本文将利用流行学习方法解决这类问题。

1.2.2 流形学习的发展情况

1984年斯坦福大学统计系的Hastie在一份技术报告中首次提出主曲线和主曲面的概念。“流形学习”的概念在1995年由Bregler和Omohundro首次提出，主要用于语音识别和图像插值中。2000年Seung和Lee在《科学》杂志上发表《认知的流行模式》一文，提出了视觉感知的流行结构假说。就在同年同期的《科学》上还刊登了另外两篇著名的文章，它们提出了两个经典算法LLE和Isomap。随着后期学者不断地深入研究，又有许多经典算法相继被提出，比如Belkin和Niyogi提出拉普拉斯特征映射算法（LE），使高维空间相近的点映射到低微空间时也相近；Donoho和Grimes提出海森特征映射（HLL），是对LLE算法的扩展；He和Hsiyogi提出局部保持投影算法（LPP），是对LE算法的线性扩展；Zhang和Zha提出局部切空间校准算法（LTSA），基于“局部拟合，全局整合”的思想；Lin和Zha提出黎曼流行（RML），利用局部黎曼正交坐标系将高维空间的数据映射到低微本质空间中去。这些经典算法被提出后，又有许多学者为了弥补这些算法的缺陷而相继提出了很多经典的改进算法。

此外，很多学者发现不同的流形学习算法之间存在着一定的联系，又提出了一些框架将多种流形学习算法纳入其中，比如经典的核主成分分析框架（KPCA）将MDS、LLE、LE、Isomap和谱聚类进行统一，GA框架在将LE、LLE、LPP和Isomap等流形学习方法纳入其中的同时又将PCA和LDA等传统线性降维方法统一进去。

本文将介绍LGE（线性图嵌入）框架，该框架由浙江大学计算机学院的蔡登教授等人开发，为基于图的子空间学习提供一般框架，该框架将LPP，NPE，IsoProjection，LSDA，MMP等流形学习算法进行统一，本文将在2.5节中详细介绍LGE算法的推导过程和算法实现流程。

1.2.3 流形的定义

关于豪斯多夫（Hausdorff）空间，直观的理解：如果某空间中任两点可用开集合将彼此“豪斯多夫”开来，该空间就是“豪

斯多夫”的。

拓扑流形：设 M 是豪斯多夫（Hausdorff）空间，若对 M 中的任意一点 $x \in M$ ，都存在 x 的一个邻域 U 与 R^d 中的一个开集同胚，则称 M 是一个 d 维的拓扑流形，简称 d 维流形。

根据上述定义可以看出，欧氏空间 R^d 本身就是一个 d 维流形。除了拓扑流形，学者们还进一步定义了微分流形、光滑流形、等距流形和黎曼流形等概念。

1.2.4流形学习的定义

给定高维数据集 $X=\{x_1, x_2, \dots, x_N\} \subset R^D$ ，并假设 X 中的样本是由低维空间中的数据 $y=\{y_1, y_2, \dots, y_N\} \subset R^d (d \ll D)$ 通过某个未知的线性变换 g 所生成，即： $x_i = g(y_i) + \epsilon_i$

其中， ϵ_i 表示噪声， $g: R^d \rightarrow R^D$ 是 C^∞ 的嵌入映射。那么流形学习的目的是通过观测数据集 X ：

(1) 获取低维表示 $y=\{y_1, y_2, \dots, y_N\} \subset R^d$ 。

(2) 构造高维空间到低维空间的非线性降维映射 $g^{-1}: R^D \rightarrow R^d$ 。

1.3小结

本文主要用到NPE算法和IsoProjection算法并详细介绍算法实现原理，本文会在后面介绍正交的NPE和IsoProjection算法，并对比这些算法的优缺点。

2流形学习相关算法

NPE和IsoProjection算法的实现需要用到LGE算法，IsoProjection算法因为涉及最短路径选择所以用到迪杰斯特拉算法，而IsoProjection算法又是基于ISOMAP算法的改进，ISOMAP算法又涉及到MDS算法。通过LGE算法构造OLGE算法要用到规范正交基。

2.1规范正交基

定义：设 $V \subset R^n$ 是一个向量空间。

(1) 若 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是向量空间 V 的一个基，且是一个两两正交的向量组，那么就称 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是向量空间 V 的一个正交基。

(2) 若 e_1, e_2, \dots, e_r 是向量空间 V 的一个基， e_1, e_2, \dots, e_r 两两正交，且都是单位向量，则称 e_1, e_2, \dots, e_r 是向量空间 V 的一个规范正交基（或标准正交基）。

求法：设 $\alpha_1, \dots, \alpha_r$ 是向量空间 V 的一个基，要求 V 的一个规范正交基，也就是要找一组两两正交的单位向量 e_1, \dots, e_r ，使 e_1, \dots, e_r 与 $\alpha_1, \dots, \alpha_r$ 等价。这一过程称为把基 $\alpha_1, \dots, \alpha_r$ 规范正交化。

可以先进行施密特正交化在进行单位化。本节接下来将详细介绍施密特正交化和单位化的计算方法。

2.1.1施密特(Schmidt)正交化

令： $\beta_1 = \alpha_1$ ； $\beta_2 = \alpha_2 - \beta_1 \alpha_2 \beta_1, \beta_1 \beta_1$ ；

..... $\beta_r = \alpha_r - \beta_1 \alpha_r \beta_1, \beta_1 \beta_1 - \beta_2 \alpha_r \beta_2, \beta_2 \beta_2 - \dots - \beta_{r-1} \alpha_r \beta_{r-1}, \beta_{r-1} \beta_{r-1}$ ，

则易验证 β_1, \dots, β_r 两两正交，且 β_1, \dots, β_r 与 $\alpha_1, \dots, \alpha_r$ 等价。且满足：对任何 $k, 1 \leq k \leq r$ ，向量组 β_1, \dots, β_k 与 $\alpha_1, \dots, \alpha_k$ 等价。

2.1.2单位化

令： $e_1 = \beta_1 \beta_1, e_2 = \beta_2 \beta_2, \dots, e_r = \beta_r \beta_r$ ，

则 e_1, e_2, \dots, e_r 是 V 的一个规范正交基。

施密特正交化过程中可将 R^n 中的任一线性无关的向量组 $\alpha_1, \dots, \alpha_r$ 化为与之等价的正交向量组 β_1, \dots, β_r ；在经过单位化，得到与 $\alpha_1, \dots, \alpha_r$ 等价的规范正交向量组 e_1, e_2, \dots, e_r 。

2.2迪杰斯特拉(Dijkstra)算法

迪杰斯特拉(Dijkstra)提出了一个按路径长度递增的次序产生最短路径的算法。

该算法利用广度优先搜索的思想，从起始点向外逐渐搜索，直到找到最终点为止。

2.2.1迪杰斯特拉(Dijkstra)算法流程

1. 准备工作。指定一个起点 s ，并且引入两个集合 S 和 U ： S 集合记录已算出最短路径的顶点和相应最短路径的长度； U 集合记录还未求出最短路径的顶点和该顶点到 S 的距离，若不相邻则为 ∞ 。

2. S 中只有 s ， U 中是其他顶点。

3. 将 U 中的最短顶点移除并加入 S 中。

4. 更新 U 。

5. 重复3、4步，直到遍历完所有顶点。

2.3 多维缩放(MDS)算法

MDS与PCA一样，是一种有效的降维方式，其可获得样本间相似性的空间表达。MDS的原理可以简述为，利用样本的成对相似性，构建一个低维空间，使每对样本在高维空间的距离与在构建的低维空间中的样本相似性尽可能保持一致。

2.3.1 MDS算法推导

MDS算法的核心思想是：降维前后，各自样本间的距离是不变的。由此可得到如下关系：假设 m 个样本在原始空间的距离矩阵为 $dist=(dist_{ij})_{m \times m}$ ，则原空间中的两样本 x_i, x_j 之间的距离 $dist_{ij}$ 等于降维后这两样本 z_i, z_j 之间的距离 $z_i - z_j$ ，即 $dist_{ij} = z_i - z_j$ ， B 为降维后样本的内积矩阵： $B = ZT^T \in R^{m \times m}$ ， $b_{ij} = z_i^T z_j$ #式2-1

Z 就是样本集在降维后空间的坐标矩阵。

所以，根据降维前后各样本间欧式距离保持不变，得： $dist_{ij}^2 = z_i^2 + z_j^2 - 2z_i^T z_j = b_{ii} + b_{jj} - 2b_{ij}$ #式2-2

假设降维后的样本集 Z 被中心化，即 $i=1, m, z_i=0$ ，则矩阵 B 的每行之和均为零，每列之和均为零，即： $i=1, m, b_{i,j}=0, j=1, 2, \dots, m, m, j=1, m, b_{i,j}=0, i=1, 2, \dots, m$

为表示方便将 $dist$ 简写为 d ，则有

$i=1, m, d_{ij}^2 = b_{ii} + b_{jj} - 2b_{ij}, j=1, 2, \dots, m, b_{ij} = \frac{1}{2}(d_{ij}^2 - d_{ii} - d_{jj}), i=1, 2, \dots, m, j=1, 2, \dots, m$

其中 tr 表示矩阵的迹。

令： $d_i \cdot 2 = 1, N_j = 1, m, d_{ij}^2 = tr(BN + b_{i,j})$ #式2-3, $d_j \cdot 2 = 1, N_i = 1, m, d_{ij}^2 = tr(BN + b_{j,i})$ #式2-4, $d_i \cdot 2 = 1, N_i = 1, m, d_{ij}^2 = 2tr(BN)$ #式2-5

代入式2-2得： $b_{ij} = -12dist_{ij}^2 - dist_i^2 \cdot 2 - dist_j^2 + dist_i^2 + 2 \cdot dist_j^2$ 式2-6

现在的问题是，已知B如何求Z。

对B做特征值分解： $B = VAV^T$ 式2-7

这里V是特征向量矩阵、A是由特征值构成的对角阵。此时，把A中的特征值排序后，把其中每个非0特征值拿出来构成对角矩阵A*，其对应的特征向量V*也需按特征值的大小改变排列顺序，组成新的特征向量矩阵。最终，通过以下公式完成降维操作（降到d维）： $Z = A^{-1}2V^T \in R^{d \times m}$ 式2-8

另外，在现实应用中为了有效降维，往往只需要降维后两样本间的距离应尽可能和原空间中两样本的距离相近就好了，不需要强行一致，因此上面特征值构成的对角阵和特征向量矩阵有了一些变化。

变化为：本来特征值取的是所有非0的特征值排序。现在变成排序好后，从大到小取特征值获得特征值对角矩阵A与其对应的特征向量矩阵V。比如要降维到n维，就从大到小取n个特征值。则通过以下公式完成降维操作（降到n维）： $Z = A^{-1}2V^T \in R^{n \times m}$ 式2-9

2.3.2 MDS算法流程

输入： $dist \in R^{m \times m}$ ，低维空间数d。

过程：

根据式2-3，式2-4和式2-5计算 d_i^2 、 d_j^2 和 d_{ij}^2 。

根据式2-6计算矩阵B。

根据式2-7对矩阵B进行特征值分解。

取n个最大的特征值构成对角矩阵A，并获得特征向量矩阵V。

根据式2-9完成降维，获得低维空间中的矩阵Z。

输出：低维空间中的矩阵Z。

2.4 等度量映射(ISOMAP)算法

ISOMAP算法可以理解为是对MDS算法的改造，也就是将原始空间中的距离计算从欧氏空间中的欧氏距离转换为流形上的测地距离。

由于流形结构是未知的，所以需要构造近邻连接图来计算最短路径问题。

图 2-1

从图2-1中可知，低维嵌入流形上的测地线距离（红色）不能用高维空间的直线距离计算，但能用近邻距离来近似。

2.4.1 ISOMAP算法步骤

ISOMAP算法分为三步：

1. 构造近邻连接图。利用流形与欧氏空间在局部上同胚的性质，使用欧氏距离找出每个点在低维流形上的近邻点，建立近邻连接图。
2. 计算测地距离。计算近邻连接图上任意两点的最短路径。
3. 数据嵌入。使用MDS算法。

2.4.2 ISOMAP算法流程

输入：样本集 $D = x_1, x_2, \dots, x_N$ ；近邻参数k；低维空间维数n。

过程：

对每个样本点 x_i ，计算它的k近邻；同时 x_i 与它的k近邻的距离设置为欧氏距离，与其他点的距离设置为无穷大。

通过最短路径算法计算任意两个样本点之间的距离，获得距离矩阵 $D \in R^{N \times N}$ 。

通过MDS算法，获得样本集在低维空间中的矩阵。

输出：样本集D在低维空间的投影 $Z = z_1, z_2, \dots, z_n$ 。

2.4.3 ISOMAP算法的特点

ISOMAP算法的优点是使用了测地距离来计算样本间的距离，这样可以更好地反映流形结构，可以减少数据的流失，使高维数据可以更全面的映射到低维空间。

指 标		
疑似剽窃文字表述		
1. 该生对本课题相关的知识与理论研究比较透彻，本设计基本实现了需求所描述的功能。		
2. 人脸识别技术不仅具有非侵犯性，而且符合人们自身识别习惯，是一种非常“人性化”的技术。		
3. 5%，然而，在同等条件下的最高人眼识别率仅为97.52%。所以，人脸识别的准确率已经做到了比肉眼更精准，		
4. 流形学习		
流形学习的主要思想是将高维的数据映射到低维，使该低维的数据能够反映原高维数据的某些本质结构特征。		
流形学习		
2. 50264765936905568_姜希成_本科论文_第2部分		总字数：14224
相似文献列表		
去除本人已发表文献复制比：11.2%(1591) 文字复制比：11.2%(1591) 疑似剽窃观点：(0)		
1	基于线性判别分析的人脸识别算法研究	9.5% (1349)
蔡佳辉 - 《大学生论文联合比对库》 - 2016-05-19		是否引证：否

2	82高新宇 - 《大学生论文联合比对库》 - 2015-06-23	1.5% (208) 是否引证：否
3	83杨泽龙 - 《大学生论文联合比对库》 - 2015-06-23	1.5% (208) 是否引证：否
4	高新宇 - 《大学生论文联合比对库》 - 2015-06-15	1.5% (208) 是否引证：否
5	邻域结构保持投影及应用 李毅英(导师：高西全;高全学) - 《西安电子科技大学博士论文》 - 2011-01-01	0.3% (37) 是否引证：否
6	人脸图像的检测和识别的研究与实现 柯江民(导师：孙淑霞) - 《成都理工大学硕士论文》 - 2009-05-01	0.3% (37) 是否引证：否
7	人脸识别研究综述 李苗在;谷海红; - 《电脑知识与技术》 - 2011-08-25	0.3% (37) 是否引证：否
8	基于EHMM的人脸识别算法 王国盛;张霞;褚洪婧; - 《现代计算机(专业版)》 - 2014-02-15	0.3% (37) 是否引证：否
9	基于Gabor和CS-LBP的人脸识别研究 唐婉冰;邵鹏威;段晨辉;陈雨晗;李琛; - 《中国科技信息》 - 2016-09-19 1	0.3% (37) 是否引证：否
10	基于子空间算法的人脸识别 靳丽丽(导师：陈秀宏) - 《江南大学博士论文》 - 2011-03-01	0.3% (37) 是否引证：否
11	自适应特征提取的光照鲁棒性人脸识别 王美;梁久祯; - 《计算机工程与应用》 - 2011-07-14 1	0.3% (36) 是否引证：否
12	聚类中心自动确定的谱聚类算法研究 陈晋音;吴洋洋;林翔; - 《小型微型计算机系统》 - 2018-08-15	0.3% (36) 是否引证：否
13	基于协作AdaBoost的多特征多姿态人脸检测研究 史万莉(导师：曾光宇) - 《中北大学博士论文》 - 2011-06-03	0.3% (36) 是否引证：否
原文内容		

ISOMAP算法还有一个很大的缺点，对于新的样本，难以将其映射到低维空间。理论上虽然可以将新样本添加到样本集中，然后重新调用ISOMAP算法，但是这种方法的计算量太大了。解决方法是：训练一个回归学习器来对新样本的低维空间进行预测。再者ISOMAP算法本身的拓扑不稳定性会导致图的错误链接，其次ISOMAP算法针对的是凸形流形，对于其他流形ISOMAP算法将无法处理。ISOMAP算法对流形中的“孔洞”也不能很好地处理。

2.5线性图嵌入算法(LGE)

为基于图的子空间学习提供一般框架。该算法将由NPE和IsoProjection调用。

2.5.1 LGE算法推导

数据集 $X=w_1, \dots, w_n, w_i \in R^m$ ， n 表示样本数量， m 表示样本维度。LGE算法采用无向有权图 $G(V, W)$ 描述数据集的流形结构，顶点集 $V=v_1, \dots, v_n$ 对应数据 w_i ， $W=w_{ij} \times n$ ， w_{ij} 表示 v_i, v_j 边的权重， W 矩阵是对称的。LGE算法在保持图的邻接关系的前提下，寻找 X 的低维表示。令 $y=y_1, \dots, y_n$ 表示从图到实线的映射，则LGE的目标函数如下： $\min_i \|y_i - y_j\|_2^2 w_{ij}$

变换后可得： $\sum_i \|y_i - y_j\|_2^2 w_{ij} = y^T L y$ ， $L = D - W$

L 是图的拉普拉斯矩阵， D 是对角矩阵， D_{ii} 对应 W 矩阵第 i 列（行）所有元素之和，即 $D_{ii} = \sum_j w_{ij}$ 。

令 $y^T D y = 1$ （消除嵌入时的量化影响），则： $\arg \min y^T D y = 1 y^T L y = \arg \min y^T L y y^T D y$

若图到实线的映射为线性，则 $y = X T a$ ，则： $\arg \min y^T D y = 1 y^T L y = \arg \min a^T X^T L X T a$

则最优向量 a 对应于以下最小特征值所对应的特征向量。 $X^T L X T a = \lambda X^T D X T a$

矩阵 $X^T D X T$ 通常是奇异的，所以LGE算法要先把 X 集投影到PCA空间，使 $X^T D X T$ 变成可逆矩阵，然后求解特征值问题。经过PCA处理后上式可通过奇异值分解进行求解： $X^T D X T - 1 X^T L X T w = \lambda w$

可解出 W_{LGE} ，设 W_{PCA} 为PCA空间特征向量，则LGE算法的解为： $W = W_{PCA} W_{LGE} X^T D X T - 1 X^T L X T$ 矩阵是非对称的，所以LGE算法的解往往是非正交的。本节会在接下来介绍正交的LGE算法(OLGE)。

许多常用的线性子空间算法如LPP等，都可以通过定义其权重矩阵 W 将该算法统一于LGE框架下，通过 $X^T L X T a = \lambda X^T D X T a$ 进行求解。

TODO：参考论文：直接线性图嵌入算法及其人脸识别中的应用

2.6局部线性嵌入算法 (LLE)

LLE是流形学习方面经典的局部非线性方法，它试图保留邻域内样本之间的线性关系。它有参数少、计算快、易求全局最优并在图像分类、图像识别、谱重建、数据可视化等方面都有着广泛的应用。

2.6.1 LLE算法原理

矩阵 $X=x_1, x_2, \dots, x_N$ 是数据矩阵，包括所有的训练样本 $x_i, i=1 \dots N \in R^m$ 。维度 m 通常是很大的，（稀疏）线性降维的目标是变换数据从原来的高维空间到低维空间。 $y=A T x \in R^d, 1 \leq d \leq m$ ， $x \in R^m$ ， $A=a_1, a_2, \dots, a_d$ 并且 $a_{ii}=1, \dots, d$ 是一个 m 维列向量。

若相邻样本处于非线性流形的局部线性片上，则每个样本 x_i 可由其 k 个最近邻居的加权线性组合近似表示。最小化如下成本函数： $\epsilon W = \sum_i \|x_i - \sum_{j \in N_k(x_i)} w_{ij} x_j\|_2^2$ ， $\sum_{j \in N_k(x_i)} w_{ij} = 1$ ， $N_k(x_i)$ 是 x_i 的 k 个最近邻居索引集， w_{ij} 是最佳局部最小二乘重建系数。得到 W 后，可以通过最小化一下函数来得到最终嵌入坐标。 $\epsilon Y = \sum_i \|y_i - \sum_{j \in N_k(x_i)} w_{ij} y_j\|_2^2 = \text{tr}(Y^T W Y - W Y^T W Y)$ s.t. $Y^T Y = I, Y = [y_1, y_2, \dots, y_d]$ 。对应于特征函数的较小特征值的特征向量是数据集的最终嵌入。 $I - W Y^T W Y = \lambda Y^T W Y$

其中 y 是对应于特征值 λ 的特征向量。

2.6.2 LLE算法推导

2.6.3 LLE算法流程

输入：数据集 X ，邻居个数 k ，降至的维度 d 。

第一步：计算对应距离和寻找邻居。

先计算向量 x_i 到 x_j 的距离，得到距离矩阵 $distance$ ，然后每行排序，取前 k 个，对应原下标就是近邻点的编号。

第二步：解决重建权重问题。

对于任意 i ，若 j 不属于 N_{kx_i} ，则 $W_{ij}=0$ ，故 W 只需存 K 行 N 列。

当且仅当每一项求和项极小时， ϵW 极小。因此需要计算每一项的极小值，也就是极小化 $\sum_{j \in 1, \dots, k} W_{ij} x_j$ s.t. $\sum_{j \in 1, \dots, k} W_{ij} = 1$ 。

第三步：从成本矩阵的特征嵌入计算 $M = I - WT(I - W)$ 。

第四步：嵌入计算。

输出：降维后的矩阵 Y 。

2.7 等距映射算法 (IsoProjection)

IsoProjection是ISOMAP的线性近似，

TODO：简介，

2.7.1 IsoProjection算法推导

设 $X = x_1, \dots, x_N$ 为输入数据集，其中 $x_i \in R^n$ ，寻找投影矩阵 W 使得 $y_i = W^T x_i$ ，其中 $y_i \in R^d, d \ll n$ 。 Y 就是降维后的数据集。

定义一个距离矩阵 D ， D_{ij} 表示 x_i 到 x_j 之间的测地距离，定义矩阵 S 令 $S_{ij} = D_{ij}^2$ ，令 $H = I - \frac{1}{N} \mathbf{1}\mathbf{1}^T$ ， I 为单位矩阵， $\mathbf{1}$ 为元素全为1的列向量，则可得内积矩阵： $P = -\frac{1}{2} H S H$ 。则IsoProjection的目标函数如下： $w = \arg \max_w w^T P X T w$ s.t. $w^T X X T w = 1$

使用拉格朗日算法将上式的解向量问题转化为求解下式的特征值和特征向量的问题。 $X P X T w = \lambda X X T w$

所以要求 $X X T$ 是非奇异矩阵，因此IsoProjection的最佳投影向量就是上式最大特征值所对应的特征向量。

IsoProjection算法求出来的投影向量往往是非正交的，这种非正交的性质会在从高维空间向低维空间的投影过程中扰乱数据的流形结构，而且会使算法本身对降维后的子空间的维数十分敏感，很难估计样本的内蕴维数。

2.7.2 IsoProjection算法流程

IsoProjection算法分五步执行：

1. 先使用PCA算法对样本进行降维。因为 $X X T$ 是奇异矩阵，所以要进行去奇异处理。使用PCA算法的主要目的是将 $X X T$ 变为非奇异矩阵，然后在低维空间使用IsoProjection算法。

2. 使用K-近邻方法构造近邻图 G 。

3. 使用迪杰斯特拉算法计算最短路径矩阵 D 。

4. 计算最佳投影矩阵 W 。

5. 特征提取。令 $W = W_{PCA} W_{IsoP}$ ，则 $x \rightarrow y = V^T x$ 。

IsoProjection算法核心源码参见附录6.1.1。

2.8 领域保护嵌入算法 (NPE)

TODO：简介。参考论文：

2.8.1 NPE算法推导

令NPE算法的权重矩阵为 S ， w 为一投影向量，使得满足 $y_i = w^T x_i$ 。则NPE算法的目标函数如下： $w_{opt} = \arg \min_w \sum_{i,j} S_{ij} (y_i - y_j)^2$ s.t. $w^T X X T w = 1$

对该目标函数做出如下推导： $w_{opt} = \arg \min_w \sum_{i,j} S_{ij} (y_i - y_j)^2 = \min_w \text{tr}(w^T X L X^T w) = \min_w \text{tr}(w^T X M X^T w)$

上式中，令 $M = L - S$ 。则简化后的目标函数如下： $w_{opt} = \arg \min_w w^T X M X^T w$

则NPE算法的最佳投影向量就是以下特征方程的最小特征值所对应的特征向量。 $X M X^T w = \lambda X X T w$

2.8.2 NPE算法流程

NPE算法的实现分为三步：

1. 构造近邻图。使用K-近邻法寻找与数据点欧氏距离最近的 K 个近邻点。

2. 确定权值。用近邻对各个数据点进行重构。

3. 计算特征映射。在低维空间中，对各个进行数据点重构，即在保持重构权值不变的情况下，使重构误差最小，计算出降维矩阵。

NPE算法核心源码参见附录6.1.2。

3 正交化算法

3.1 OlsoProjection

OlsoProjection算法是在IsoProjection算法的基础上，得到一组正交基向量，因此该算法在保留IsoProjection算法线性的特点的同时又能够保持高维数据的流形结构。

OlsoProjection算法希望通过一组正交基改造目标函数，正交基的求法也相类似，都是通过拉格朗日乘子法引入正交基约束条件来推导出一个特征方程，然后求出该特征方程的最大特征值对应的特征向量以求出正交基，再利用该正交基构造特征方程进行特征提取。

3.1.1 OlsoProjection算法推导

首先要计算出一组正交基 w_1, w_2, \dots, w_d ，则目标函数如下： $w_1 = \arg \max_w w^T P X T w$ s.t. $w^T X X T w = 1$

$w_1^T X X T w_1 = 1, w_2 = \arg \max_w w^T P X T w$ s.t. $w^T X X T w = 1, w^T w_1 = 0$ ， $w_3 = \arg \max_w w^T P X T w$ s.t. $w^T X X T w = 1, w^T w_1 = 0, w^T w_2 = 0$ ， \dots ， $w_d = \arg \max_w w^T P X T w$ s.t. $w^T X X T w = 1, w^T w_1 = 0, w^T w_2 = 0, \dots, w^T w_{d-1} = 0$

则向量 w_1 可以通过求解 $X P X T w = \lambda X X T w$ 特征方程的最大特征值所对应的特征向量获得。

若已有 $d-1$ 个正交基向量 w_1, w_2, \dots, w_{d-1} 。则可以利用如下正交约束条件获得 w_d ： $w_d^T w_1 = w_d^T w_2 = \dots = w_d^T w_{d-1} = 0$ 。

利用拉格朗日乘子法得到如下方程： $L_{wd} = w_d T X P X T w_d - \lambda w_d T X X T w_d - 1 - i = 1 - d - 1 \beta_i w_d T w_i$ #式3-2

令： $\partial L_{wd} / \partial w_d = 0$ ，则： $2 X P X T w_d - 2 \lambda X X T w_d - i = 1 - d - 1 \beta_i w_i = 0$ #式3-3

方程两边同时左乘 $w_d T$ ： $2 w_d T X P X T w_d - 2 \lambda w_d T X X T w_d = 0$ #式3-4

得： $\lambda = w_d T X P X T w_d / w_d T X X T w_d$ #式3-5

将(9.1.1.2)式方程两边同时左乘 $w_1 T(X X T) - 1, w_2 T(X X T) - 1, \dots, w_{d-1} T(X X T) - 1$ ，得到 $d-1$ 个式子： $2 w_1 T(X X T) - 1 X P X T w_d - i = 1 - d - 1 \beta_i w_1 T(X X T) - 1 w_i = 0, 2 w_2 T(X X T) - 1 X P X T w_d - i = 1 - d - 1 \beta_i w_2 T(X X T) - 1 w_i = 0, \dots, 2 w_{d-1} T(X X T) - 1 X P X T w_d - i = 1 - d - 1 \beta_i w_{d-1} T(X X T) - 1 w_i = 0$

为方便求解做出如下定义： $\beta(d-1) = [\beta_1, \beta_2, \dots, \beta_{d-1}]^T$ ； $W_{d-1} = [w_1, w_2, \dots, w_{d-1}]^T$ ； $S_{ij}(d-1) = w_i T(X X T) - 1 w_j$ ； $S(d-1) = [S_{ij}(d-1)] = [W_{d-1}]^T (X X T) - 1 W_{d-1}$ ；

所以就可以用矩阵形式表示这 $d-1$ 个方程了： $2 W_{d-1} T X X T - 1 X P X T w_d - S_{d-1} \beta_{d-1} = 0$ #式3-6

得： $\beta_{d-1} = 2 S_{d-1}^{-1} W_{d-1} T X X T - 1 X P X T w_d$ #式3-7

将(9.1.1.2)两边同乘 $(X X T) - 1$ ，得： $2 X X T - 1 X P X T w_d - 2 \lambda w_d - i = 1 - d - 1 \beta_i X X T - 1 w_i = 0$ #式3-8

矩阵表示： $2 X X T - 1 X P X T w_d - 2 \lambda w_d - X X T - 1 W_{d-1} \beta_{d-1} = 0$ #式3-9

由式3-7和式3-9得： $I - X X T - 1 W_{d-1} S_{d-1}^{-1} W_{d-1} T X X T - 1 X P X T w_d = \lambda w_d$ #式3-10

得： $U_d = I - X X T - 1 W_{d-1} S_{d-1}^{-1} W_{d-1} T X X T - 1 X P X T$ #式3-11

得特征方程： $U_d w_d = \lambda w_d$ #式3-12

可通过求解上式最大特征值对应的特征向量得到正交基 w_k 。

所以，OlsoProjection算法的正交投影向量就是特征方程 $U_d w_d = \lambda w_d$ 的最大特征值所对应的特征向量。

3.1.2 OlsoProjection算法流程

OlsoProjection算法的前三步与IsoProjection算法的步骤相同，此处不再赘述。直接从第四步开始介绍：

4. 计算正交投影向量。

通过5.2.1中的算法计算出一组正交基 w_1, w_2, \dots, w_d ，具体流程如下：

(2) 通过求解 $X P X T w = \lambda X X T w$ 特征方程的最大特征值所对应的特征向量获得计算 w_1 。

(2) 通过求解 $U_k w_k = \lambda w_k$ 特征方程的最大特征值所对应的特征向量获得 w_k ， $k=2, 3, \dots, d$ 。

5. 特征提取。

令通过OlsoProjection算法得到的最佳投影矩阵为 d 维的 W_{OlsoP} ，通过PCA算法得到的投影矩阵为 W_{PCA} ，则令 $V = W_{PCA} W_{OlsoP}$ ，则通过线性嵌入： $x \rightarrow y = V T x$ #式3-13

可以得到对任意 x 的 d 维特征。

3.2 ONPE

ONPE算法在NPE算法的基础上添加了正交迭代处理。改进的思路与OlsoProjection算法类似，算法的推导过程也与OlsoProjection算法类似。

3.2.1 ONPE算法推导

定义邻域保护函数为： $f_a = a T X M X T a a T X X T a$ ， $a \in R^n$ #式3-14

最小化该函数将得到NPE算法，而ONPE算法既要找到一组正交向量又要满足上式最小，因此ONPE算法的目标函数如下： $a_1 = \arg \min a a T X M X T a a T X X T a$ $a_k = \arg \max a a T X M X T a a T X X T a$ $a_k T a_1 = a_k T a_2 = \dots = a_k T a_{k-1} = 0, a_k T X X T a_k = 1$ #式3-15 a_1 可以通过求解 $(X X T) - 1 X M X T$ 的最小特征对应的特征向量获得。

若已有 $k-1$ 个正交向量 a_1, a_2, \dots, a_{k-1} ，则第 k 正交向量满足以下条件： $\min a_k T X M X T a_k a_k T X X T a_k$ #式3-16

约束条件： $a_k T a_1 = a_k T a_2 = \dots = a_k T a_{k-1} = 0, a_k T X X T a_k = 1$ 。

利用拉格朗日乘子法得到如下方程： $C_k = a_k T X M X T a_k - \lambda a_k T X X T a_k - \mu_1 a_k T a_1 - \dots - \mu_{k-1} a_k T a_{k-1}$ #式3-17

令： $\partial C_k / \partial a_k = 0$ ，则： $2 X M X T a_k - 2 \lambda X X T a_k - \mu_1 a_1 - \dots - \mu_{k-1} a_{k-1} = 0$ #式3-18

得： $\lambda = a_k T X M X T a_k a_k T X X T a_k$ #式3-19。1.2.2式两边同时左乘 $a_j T(X X T) - 1, j=1, 2, \dots, k-1$ ，得到 $k-1$ 个式子： $2 a_j T X X T - 1 X M X T a_k = \mu_1 a_j T X X T - 1 a_1 + \dots + \mu_{k-1} a_j T X X T - 1 a_{k-1}$ #式3-20

其中 $j=1, 2, \dots, k-1$ 。

为方便求解做如下定义： $\mu(k-1) = (\mu_1, \mu_2, \dots, \mu_{k-1})^T$ ； $A(k-1) = (a_1, a_2, \dots, a_{k-1})^T$ ； $B(k-1) = [B_{ij}(k-1)] = [A(k-1)]^T (X X T) - 1 A(k-1)$ ；

所以就可以用矩阵形式表示这 $k-1$ 个方程了： $B_{k-1} \mu_{k-1} = 2 A_{k-1} T X X T - 1 X M X T a_k$ #式3-21

得： $\mu_{k-1} = 2 B_{k-1}^{-1} A_{k-1} T X X T - 1 X M X T a_k$ #式3-22。1.2.2式两边同时左乘 $X X T - 1$ ，得： $2 X X T - 1 X M X T a_k - 2 \lambda a_k - X X T - 1 A_{k-1} \mu_{k-1} = 0$ #式3-23

通过9.1.2.6式和9.1.2.7式得： $I - X X T - 1 A_{k-1} B_{k-1}^{-1} A_{k-1} T X X T - 1 X M X T a_k = \lambda a_k$ #式3-24

令： $U_k = I - X X T - 1 A_{k-1} B_{k-1}^{-1} A_{k-1} T X X T - 1 X M X T$ #式3-25

得特征方程： $U_k a_k = \lambda a_k$ #式3-26

通过求解这个特征方程就能得到一组正交投影向量。

所以，ONPE算法的正交投影向量就是特征方程 $U_k a_k = \lambda a_k$ 的最大特征值所对应的特征向量。

3.2.2 ONPE算法流程

ONPE算法的前两步与NPE算法一样，这里从第三步开始介绍：

3. 计算正交投影向量。通过5.2.1中的算法计算出一组正交投影向量 a_1, a_2, \dots, a_k 。

1) 通过求解 $(X X T) - 1 X M X T$ 的最小特征对应的特征向量获得 a_1 。

2) 通过求解5.2.1.5的最小特征对应的特征向量获得 a_k 。

4. 特征提取。

令通过ONPE算法得到的最佳投影矩阵为 d 维的 W_{ONPE} ，通过PCA算法得到的投影矩阵为 W_{PCA} ，则令 $V = W_{PCA} W_{ONPE}$ ，则通过线性嵌入： $x \rightarrow y = V T x$ #式3-27

可以得到对任意 x 的 d 维特征。

4 算法实现

在本节中，将分别运行NPE、ONPE、IsoProjection和OlsoProjection算法，并对比这些算法，分析这些算法的优缺点。

4.1 常用的人脸数据库介绍

使用公开人脸数据库对程序进行测评是评判算法好坏的主要依据。常用的人脸数据库有：FERET人脸库，由美国国防部为研发自动人脸识别系统而创建的人脸库；Yale人脸库和Yale B人脸库，由耶鲁大学计算视觉与控制中心创建；ORL人脸库，由剑桥大学AT&T实验室创建；AR人脸库，由西班牙巴塞罗那计算机视觉中心创建；XM2VTS人脸库，由欧洲ACTS项目的研究计划M2VTS资助建立的身份认证资料数据库，是一个商业收费数据库；CMU PIE库，是卡耐基梅隆大学创建。

本文将在ORL人脸库和Yale人脸库上进行试验。

4.2 在ORL人脸库上进行实验

4.2.1 ORL人脸库介绍

ORL人脸库由剑桥大学AT&T实验室创建，该库由40个人，每人10张图像，共400张图像组成。图像均在不同光照、不同角度和不同表情下获得。每张图片的分辨率均为112times92像素。该库的面部表情变化主要是笑/不笑和睁眼/闭眼，还有一些其他的面部细节。拍摄的是受试者的正面、垂直头像，允许倾斜或旋转。

图 4-2

图4-1是ORL人脸库的示例图片。

人脸库下载：<http://www.cl.cam.ac.uk/research/dtg/attarchive/facedatabase.html>

4.2.2 实验结果

4.3 在Yale人脸库上进行实验

4.3.1 Yale人脸库介绍

Yale人脸数据库是由耶鲁大学计算视觉与控制中心创建的。该人脸库是由15个人每人11张图片共165张图片组成，分别基于不同的光照变化、表情变化和姿态变化，如眨眼、正常、瞌睡、惊奇、悲伤和高兴，还有佩戴眼镜的人脸图像。

图 4-3

图4-1是Yale人脸库的示例图片。

人脸库下载：<http://cvc.yale.edu/projects/yalefaces/yalefaces.html>

4.3.2 实验结果

4.4 分析

从上述实验结果可以看出，ONPE算法和OlsoProjection算法的识别率要优于NPE算法和IsoProjection算法，这说明该正交化方案是有效的。

5 结束语

毕业设计终于顺利完成，实验结果也比较符合预期。

其实本文的结构顺序完全符合我的学习历程，在我刚开始接触人脸识别和流形学习的时候，先是查阅了很多介绍流形学习的文献，其中我觉得重要的东西都整理在了第一节中，然后我就开始学习一些经典的流形学习算法，比如MDS算法、LLE算法、LPP算法、PCA算法、NPE算法、ISOMAP算法、LGE框架和IsoProjection算法等等，在我确定了毕业设计要研究什么的时候，我有在网上查阅一些如何将算法正交化核化的文献，在学习过程中，我认为我最大的收获是学习了一种思维模式，这给我的思想中种下了一颗种子。

在最后的实验过程中，我遇到了许许多多的障碍，比如在第一次实验过程中发现正交化算法的识别率竟然只有百分之四五十的样子，当时这个问题阻碍了我很久，后来才发现原来是程序设计上忽略了OLGE框架的正确用法。

流形学习其实是有章可循的，尽管其在过去几年取得了丰硕的成果，但因其数学理论基础较为复杂，以及学科间存在交叉融合，所以这也意味着流形学习还具有广阔的发展空间。

6 附录

6.1 主要算法的核心代码

详见中国浙江大学计算机学院的蔡登教授的个人主页：

<http://www.cad.zju.edu.cn/home/dengcai/Data/DimensionReduction.html>

6.1.1 IsoProjection算法

```
if options.k <= 0 % Always supervised!
```

```
Label = unique(options.gnd);
```

```
nLabel = length(Label);
```

```
G = zeros(nSmp,nSmp);
```

```
for i=1:nLabel
```

```
classIdx = find(options.gnd==Label(i));
```

```
D = EuDist2(data(classIdx,:),[],1);
```

```
G(classIdx,classIdx) = D;
```

```
end
```

```
maxD = max(max(G));
```

```
% effectively infinite distance
```

```
INF = maxD*INFRatio;
```

```
D = INF*ones(nSmp,nSmp);
```

```
for i=1:nLabel
```

```
classIdx = find(options.gnd==Label(i));
```

```
D(classIdx,classIdx) = G(classIdx,classIdx);
```

```
end
```



```

Else
switch lower(options.NeighborMode)
case {lower('KNN')}
D = EuDist2(data);
maxD = max(max(D));
% effectively infinite distance
INF = maxD*INFratio;
[dump,iidx] = sort(D,2);
iidx = iidx(:,(2+options.k):end);
for i=1:nSmp
D(i,iidx(i,:)) = 0;
end
D = max(D,D');
D = sparse(D);
D = dijkstra(D, 1:nSmp);
D = reshape(D,nSmp*nSmp,1);
inflidx = find(D==inf);
D = reshape(D,nSmp,nSmp);
case {lower('Supervised')}
Label = unique(options.gnd);
nLabel = length(Label);
G = zeros(nSmp,nSmp);
maxD = 0;
for idx=1:nLabel
classlidx = find(options.gnd==Label(idx));
nSmpClass = length(classlidx);
D = EuDist2(data(classlidx,:),[],1);
if maxD < max(max(D))
maxD = max(max(D));
end
if options.k >= nSmpClass
G(classlidx,classlidx) = D;
else
[dump,iidx] = sort(D,2);
iidx = iidx(:,(2+options.k):end);
for i=1:nSmpClass
D(i,iidx(i,:)) = 0;
end
D = max(D,D');
D = sparse(D);
D = dijkstra(D, 1:nSmpClass);
G(classlidx,classlidx) = D;
end
end
% effectively infinite distance
INF = maxD*INFratio;
D = INF*ones(nSmp,nSmp);
for i=1:nLabel
classlidx = find(options.gnd==Label(i));
D(classlidx,classlidx) = G(classlidx,classlidx);
end
end
end
S = D.^2;
sumS = sum(S);
H = sumS*ones(1,nSmp)/nSmp;
TauDg = -.5*(S - H - H' + sum(sumS)/(nSmp^2));
TauDg = max(TauDg,TauDg');
[eigvector,eigvalue]=LGE(TauDg, [], options, data);
eiglidx = find(eigvalue < 1e-3);
eigvalue (eiglidx) = [];

```

```

eigvector(:,eigIdx) = [];
6.1.2 NPE算法
if options.k <= 0 % Always supervised!
W = zeros(nSmp,nSmp);
for ii=1:nSmp
idx = find(options.gnd==options.gnd(ii));
idx(find(idx==ii)) = [];
% shift ith pt to origin
z=data(idx,:)-repmat(data(ii,:),length(idx),1);
C = z*z'; % local covariance
% regularization
C = C + eye(size(C))*tol*trace(C);
tW = C\ones(length(idx),1); % solve Cw=1
tW = tW/sum(tW); % enforce sum(w)=1
W(idx,ii) = tW;
end
M = (eye(size(W)) - W);
M = M*M';
M = max(M,M');
M = sparse(M);
Else
switch lower(options.NeighborMode)
case {lower('KNN')}
Distance = EuDist2(data,[],0);
[sorted,index] = sort(Distance,2);
neighborhood = index(:,2:(1+options.k));
case {lower('Supervised')}
Label = unique(options.gnd);
nLabel = length(Label);
neighborhood = zeros(nSmp,options.k);
for idx=1:nLabel
classIdx=find(options.gnd==Label(idx));
Distance=EuDist2(data(classIdx,:),[],0);
[sorted,index] = sort(Distance,2);
neighborhood(classIdx,:) = classIdx(index(:,2:(1+options.k)));
end
end
W = zeros(options.k,nSmp);
for ii=1:nSmp
% shift ith pt to origin
z = data(neighborhood(ii,:),:)-repmat(data(ii,:),options.k,1);
C = z*z'; % local covariance
%regularization
C = C + eye(size(C))*tol*trace(C);
W(:,ii) = C\ones(options.k,1);% solve Cw=1
% enforce sum(w)=1
W(:,ii) = W(:,ii)/sum(W(:,ii));
end
M = sparse(1:nSmp,1:nSmp,ones(1,nSmp),nSmp,nSmp,4*options.k*nSmp);
for ii=1:nSmp
w = W(:,ii);
jj = neighborhood(ii,:);
M(ii,jj) = M(ii,jj) - w';
M(jj,ii) = M(jj,ii) - w;
M(jj,jj) = M(jj,jj) + w*w';
end
M = max(M,M');
M = sparse(M);
end
M = -M;
for i=1:size(M,1)

```

```

M(i,i) = M(i,i) + 1;
end
[evector, evalue] = LGE(M, [], options, data);
eldx = find(evalue < 1e-10);
evalue(eldx) = [];
evector(:,eldx) = [];
6.1.3 LGE算法
MAX_MATRIX_SIZE = 1600;
EIGVECTOR_RATIO = 0.1;
% SVD
if bPCA
[U, S, V] = mySVD(data);
[U, S, V]=CutonRatio(U,S,V,options);
eigvalue_PCA = full(diag(S));
if bD
data = U*S;
eigvector_PCA = V;
DPrime = data*D*data;
DPrime = max(DPrime,DPrime');
else
data = U;
eigvector_PCA = V*spdiags(eigvalue_PCA.^-1,0,length(eigvalue_PCA),length(eigvalue_PCA));
end
else
if ~bChol
if bD
DPrime = data*D*data;
else
DPrime = data*data;
end
switch lower(options.ReguParamType)
case {lower('Ridge')}
if options.ReguParamAlpha > 0
for i=1:size(DPrime,1)
DPrime(i,i) = DPrime(i,i) + options.ReguParamAlpha;
end
end
case {lower('Tensor')}
if options.ReguParamAlpha > 0
DPrime = DPrime + options.ReguParamAlpha*options.regularizerR;
end
case {lower('Custom')}
if options.ReguParamAlpha > 0
DPrime = DPrime + options.ReguParamAlpha*options.regularizerR;
end
end
end
DPrime = max(DPrime,DPrime');
end
end
WPrime = data*W*data;
WPrime = max(WPrime,WPrime');
% Generalized Eigen
dimMatrix = size(WPrime,2);
if ReducedDim > dimMatrix
ReducedDim = dimMatrix;
end
if isfield(options,'bEigs')
bEigs = options.bEigs;
else
if (dimMatrix > MAX_MATRIX_SIZE) && (ReducedDim < dimMatrix*EIGVECTOR_RATIO)
bEigs = 1;

```

```

else
bEigs = 0;
end
end
if bEigs
%disp('use eigs to speed up!');
opt = struct('disp',0);
if bPCA && ~bD
[evector, evalue] = eigs(WPrime,ReducedDim,'la',opt);
else
if bChol
option.cholB = 1;
[evector, evalue] = eigs(WPrime,R,ReducedDim,'la',opt);
else
[evector, evalue] = eigs(WPrime,DPrime,ReducedDim,'la',opt);
end
end
evalue = diag(evalue);
else
if bPCA && ~bD
[eigvector, eigvalue] = eig(WPrime);
else
[eigvector, eigvalue] = eig(WPrime,DPrime);
end
eigvalue = diag(eigvalue);
[junk, index] = sort(-evalue);
evalue = eigvalue(index);
evector = eigvector(:,index);
if ReducedDim < size(eigvector,2)
evector = eigvector(:, 1:ReducedDim);
evalue = eigvalue(1:ReducedDim);
end
end
if bPCA
evector = eigvector_PCA*evector;
end
for i = 1:size(evector,2)
evector(:,i) = evector(:,i)/norm(evector(:,i));
end
%function CutonRatio
function [U, S, V]=CutonRatio(U,S,V,options)
if ~isfield(options, 'PCARatio')
options.PCARatio = 1;
end
eigvalue_PCA = full(diag(S));
if options.PCARatio > 1
idx = options.PCARatio;
if idx < length(eigvalue_PCA)
U = U(:,1:idx);
V = V(:,1:idx);
S = S(1:idx,1:idx);
end
elseif options.PCARatio < 1
sEig = sum(eigvalue_PCA);
sEig = sEig*options.PCARatio;
sNow = 0;
for idx = 1:length(eigvalue_PCA)
sNow = sNow + eigvalue_PCA(idx);
if sNow >= sumEig
break;
end

```



```

end
U = U(:,1:idx);
V = V(:,1:idx);
S = S(1:idx,1:idx);
end

```

参考文献

- [1] Deng Cai, Xiaofei He, and Jiawei Han. Isometric Projection[R]. Department of Computer Science, University of Illinois at Urbana-Champaign: Yahoo! Research Labs, 2006.
- [2] 徐勇, 范自柱, 张大鹏. 基于稀疏算法的人脸识别[M]. 北京: 国防工业出版社, 2014.
- [3] 王庆军, 张汝波, 刘冠群. 一种应用于人脸识别的核正交等度规映射算法[N]. 光电子激光, 2010(11).
- [4] 王庆军. 流形学习算法分析及应用研究[D]. 哈尔滨工程大学: 计算机科学与技术学院, 2008.
- [5] 王庆军. 基于流形学习子空间的人脸识别方法研究[D]. 哈尔滨工程大学: 计算机科学与技术学院, 2011.
- [6] 王庆军, 张汝波, 潘海为. 基于核正交局部判别嵌入的人脸识别[N]. 光电子激光, 2010(9).
- [7] 王庆军, 张汝波, 楼宋江, 吕海燕. 一种核正交局部敏感辨别分析算法[N]. 小型微型计算机系统, 2009(11).
- [8] 王庆军, 张汝波. 基于LogGabor和正交等度规映射的人脸识别[N]. 计算机科学, 2011(2).
- [9] 古楠楠, 樊明宇, 王迪, 韩志. 流形学习若干关键问题与算法研究[M]. 北京: 首都经济贸易大学出版社, 2015.
- [10] 秦鸿, 李泰峰, 郭亨艺, 许毅. 人脸识别技术在图书馆的应用研究[N]. 大学图书馆学报, 2018(6).
- [11] 徐蓉, 姜峰, 姚鸿勋. 流形学习概述[N]. 智能系统学报, 2006(1).
- [12] 高小方. 流形学习方法中的若干问题分析[N]. 计算机科学, 2009(4).
- [13] 王自强, 钱旭, 孔敏. 流形学习算法综述[N]. 计算机工程与应用, 2008(35).
- [14] 李波. 基于流形学习的特征提取方法及其应用研究[D]. 中国科学技术大学: 中国科学技术大学研究生院, 2008.
- [15] 赵连伟, 罗四维, 赵艳敏, 刘蕴辉. 高维数据流形的低维嵌入及嵌入维数研究[D]. 软件学报, 2005(16).
- [17] 张军平. 流形学习及应用[D]. 中国科学院自动化研究所: 中国科学院研究生院, 2003.
- [18] 孟德宇, 徐晨, 徐宗本. 基于Isomap的流形结构重建方法[N]. 计算机学报, 2010(3).
- [19] 李小丽, 薛清福. 几种流形学习算法的比较研究[N]. 电脑与信息技术, 2009(3).
- [20] 王靖. 流形学习的理论与方法研究[D]. 浙江大学: 理学院, 2006.
- [21] 程起才, 王洪元, 刘爱萍, 冯燕. 基于ISOMAP的一种多流形学习算法[N]. 微电子学与计算机, 2009(10).
- [22] 詹宇斌. 流形学习理论与方法及其应用研究[D]. 国防科学技术大学: 国防科学技术大学研究生院, 2011.
- [23] 黄结. 基于正交局部敏感辨别分析的人脸识别方法研究[D]. 鲁东大学: 信息与电气工程学院, 2013.
- [24] 吴赣昌. 线性代数[M]. 北京: 中国人民大学出版社, 2011.
- [25] 陈江峰. 线性图嵌入算法及其应用[D]. 北京交通大学: 信号与信息处理, 2012.
- [26] 陈江峰, 袁保宗. 直接线性图嵌入算法及其在人脸识别中的应用[N]. 电子与信息学报, 2010(6).
- [27] 严蔚敏, 吴伟民. 数据结构 (C语言版) [M]. 北京: 清华大学出版社, 2007.
- [28] 郭鹤楠. 基于NPE和LDCRF的人体运动识别[D]. 吉林大学: 计算机科学与技术(生物信息学), 2011.
- [29] 刘嘉敏, 李连泽, 罗甫林, 刘亦哲, 刘玉梅. 相关NPE算法的人脸识别研究[N]. 计算机应用研究, 2015(6).
- [30] 胡凡君, 张勤, 李鹏, 苗爱敏, 邹勋, 陈霍兴. 基于NPE算法的环网柜故障检测方法研究[N]. 自动化仪表, 2017(10).
- [31] 仝一君, 王力. 基于NPE算法的语音特征提取应用研究[N]. 通信技术, 2014(11).
- [32] 左加阔. 基于流形学习算法的新生儿疼痛表情识别[D]. 南京邮电大学: 信号与信息处理, 2011.
- [33] 陶晓燕, 姬红兵, 景志宏. 一种用于人脸识别的正交邻域保护嵌入算法[N]. 西安电子科技大学学报 (自然科学版), 2008(6).
- [34] 陶晓燕. 基于支持向量机和流形学习的分类方法研究[D]. 西安电子科技大学: 模式识别与智能系统, 2008.
- [35] 刘韵佳, 赵荣珍, 王雪冬. 基于Schur分解和正交邻域保持嵌入算法的故障数据集降维方法[N]. 中国机械工程, 2017(21).
- [36] 刘韵佳. 基于Schur-ONPE的转子故障数据集降维方法研究[D]. 兰州理工大学: 机械制造及其自动化, 2017.
- [37] 陈法法, 杨晓青, 陈保家, 程珩, 肖文荣. 基于正交邻域保持嵌入与多核相关向量机的滚动轴承早期故障诊断[N]. 计算机集成制造系统, 2018(8).
- [38] 李锋, 汤宝平, 董绍江. 基于正交邻域保持嵌入特征约简的故障诊断模型[N]. 仪器仪表学报, 2011(3).
- [39] 苗爱敏. 数据局部时空结构特征提取与故障检测方法[D]. 浙江大学, 2014.
- [40] 季云峰, 冯立元, 匡亮. 基于改进的有监督正交邻域保持嵌入的故障辨识[N]. 机械传动, 2017(1).
- [41] 陈江峰. 线性图嵌入算法及其应用[D]. 北京交通大学: 信号与信息处理, 2012.
- [42] 华校专, 王正林. Python大战机器学习: 数据科学家的第一个小目标[M]. 北京: 电子工业出版社, 2017.
- [43] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.

指 标

疑似剽窃文字表述

1. 图像, 共400张图像组成。图像均在不同光照、不同角度和不同表情下获得。每张图片的

说明: 1.总文字复制比: 被检测论文总重合字数在总字数中所占的比例

2. 去除引用文献复制比：去除系统识别为引用的文献后，计算出来的重合字数在总字数中所占的比例
3. 去除本人已发表文献复制比：去除作者本人已发表文献后，计算出来的重合字数在总字数中所占的比例
4. 单篇最大文字复制比：被检测文献与所有相似文献比对后，重合字数占总字数的比例最大的那一篇文献的文字复制比
5. 指标是由系统根据《学术论文不端行为的界定标准》自动生成的
6. 红色文字表示文字复制部分;绿色文字表示引用部分;棕灰色文字表示作者本人已发表文献部分
7. 本报告单仅对您所选择比对资源范围内检测结果负责



 amlc@cnki.net

 <http://check.cnki.net/>

 <http://e.weibo.com/u/3194559873/>

“中国知网”大学生论文检测系统